

Exponencial por diseño: por qué un millón de núcleos clásicos no puede igualar a cien buenos qubits

HPC vs. Computadores Cuánticos — De las raíces del paralelismo al pulso
Exaescala–NISQ

Esteban Hernández*

CyberColombia, Bogotá, Colombia

Julio de 2026

Resumen

La computación clásica ha dedicado cinco décadas a extraer todos los niveles de paralelismo disponibles: paralelismo a nivel de instrucción (ILP), jerarquías profundas de caché, unidades vectoriales, procesadores multinúcleo, nodos multi-socket, redes de muy baja latencia y clústeres de miles de nodos, culminando en sistemas de exaescala verificados que superan los 2×10^{18} operaciones de punto flotante por segundo. Surge una pregunta natural: si ya podemos ejecutar millones de tareas simultáneamente, ¿sigue siendo válida la premisa de que la computación cuántica es fundamentalmente más poderosa? Este artículo sostiene que sí, pero por razones frecuentemente malinterpretadas. El paralelismo clásico produce a lo sumo una aceleración *lineal* en los recursos físicos, mientras que un registro cuántico de n qubits habita un espacio de Hilbert de dimensión 2^n , que crece *exponencialmente* con hardware lineal. Crucialmente, esta ventaja no consiste en “probar todas las respuestas a la vez”: se materializa únicamente mediante interferencia cuántica, y solo para problemas con estructura explotable. Trazamos ambos paradigmas desde sus raíces teóricas (Flynn, Amdahl, Gustafson; Feynman, Deutsch, Shor, Grover), formalizamos la comparación mediante teoría de la complejidad (P, BPP, BQP), examinamos las principales tecnologías de implementación de qubits y sus perspectivas de escalado, y confrontamos la teoría con la realidad de 2026: supercomputadores de exaescala con millones de núcleos frente a dispositivos cuánticos ruidosos de escala intermedia (NISQ) con cientos de qubits físicos. Concluimos que el futuro no es el reemplazo sino la hibridación: unidades de procesamiento cuántico como aceleradores dentro de infraestructuras clásicas de HPC.

Palabras clave: computación de alto desempeño, computación cuántica, paralelismo, complejidad computacional, NISQ, exaescala, tecnologías de qubits.

1 Introducción

La historia del rendimiento computacional es, en primera aproximación, la historia del paralelismo. Cuando el escalado de frecuencia colapsó contra el muro de potencia a mediados de los años 2000, la respuesta de la industria fue multiplicar: más pipelines, más núcleos, más sockets, más nodos. Hoy la lista TOP500 está encabezada por máquinas que sostienen más de dos exaflops en el benchmark High-Performance Linpack (HPL), agregando millones de núcleos en miles de nodos conectados por redes de latencia sub-microsegundo.

Con este trasfondo, la afirmación habitual de que “los computadores cuánticos son exponencialmente más poderosos” merece escrutinio. Si un supercomputador clásico ya ejecuta 10^7

*Autor de correspondencia: esteban.hernandez@cybercolombia.org

hilos de hardware concurrentemente, ¿en qué sentido preciso puede ser más poderoso un dispositivo con unos pocos cientos de qubits frágiles? Este artículo responde esa pregunta con rigor. La Sección 2 reconstruye el stack completo del paralelismo clásico y sus límites formales. La Sección 3 presenta las raíces del paralelismo cuántico y desmonta la narrativa popular—pero incorrecta—de la “evaluación masivamente paralela”. La Sección 4 formaliza la comparación mediante complejidad computacional. La Sección 5 examina las tecnologías de implementación de qubits y sus perspectivas de escalado a corto plazo. La Sección 6 confronta el HPC de exaescala con la era NISQ. La Sección 7 argumenta a favor del modelo híbrido HPC+QC, y la Sección 8 concluye.

2 Raíces y límites del paralelismo clásico

2.1 El stack del paralelismo

El rendimiento clásico moderno es el producto del paralelismo explotado simultáneamente en todos los niveles arquitectónicos:

Paralelismo a nivel de instrucción (ILP). Pipelining, ejecución superescalar, ejecución fuera de orden, predicción de saltos y ejecución especulativa permiten que un solo núcleo retire múltiples instrucciones por ciclo. El ILP está acotado por dependencias de datos y riesgos de control; los estudios empíricos sitúan el IPC sostenible en pocas unidades para código de propósito general.

Paralelismo a nivel de datos (DLP). Las unidades vectoriales SIMD (SSE/AVX-512, SVE, warps de GPU) aplican una instrucción a registros anchos o a miles de lanes. Las GPU generalizan el DLP en ejecución SIMT con decenas de miles de hilos concurrentes por dispositivo.

Jerarquía de memoria. Las cachés multinivel (L1/L2/L3), los prefetchers y los controladores de memoria conscientes de NUMA existen para alimentar las unidades funcionales paralelas; el paralelismo efectivo suele estar acotado no por el cómputo sino por el ancho de banda de memoria (el “muro de memoria” y el modelo roofline).

Paralelismo a nivel de hilos y tareas. Multinúcleo y multithreading simultáneo dentro de un socket; múltiples sockets por nodo con memoria compartida coherente (ccNUMA).

Paralelismo a nivel de nodo y clúster. Clústeres de memoria distribuida programados con MPI, conectados por fabrics de baja latencia (InfiniBand, Slingshot) que alcanzan latencias de microsegundos y cientos de Gb/s por puerto; en el extremo, sistemas clase TOP500 con miles de nodos y millones de núcleos.

2.2 Límites formales: Amdahl y Gustafson

Sea f la fracción serial de un programa. La ley de Amdahl acota la aceleración con P procesadores:

$$S(P) = \frac{1}{f + \frac{1-f}{P}} \xrightarrow{P \rightarrow \infty} \frac{1}{f}. \quad (1)$$

La ley de Gustafson rehabilita el escalado para problemas cuyo tamaño crece con P ($S(P) = P - f(P - 1)$), que es precisamente cómo se diseñan las cargas de HPC de escalado débil. Sin embargo, ambas leyes comparten una propiedad estructural ineludible: *la aceleración es a lo sumo lineal en P* . Duplicar la capacidad exige duplicar el hardware, la energía y el costo. En términos asintóticos, una máquina paralela con P procesadores puede reducir el tiempo de un

cómputo de T pasos a lo mejor a T/P ; no puede cambiar la *clase de complejidad* de un problema. Un computador paralelo es polinomialmente equivalente a uno secuencial.

3 Raíces del paralelismo cuántico

3.1 La motivación de Feynman y la formalización de Deutsch

La computación cuántica nació de una limitación del paralelismo clásico. Feynman (1982) observó que simular un sistema cuántico de n partículas requiere recursos clásicos que crecen exponencialmente en n , y propuso que solo un computador que operara bajo reglas cuánticas podría simular la naturaleza eficientemente. Deutsch (1985) formalizó la máquina de Turing cuántica universal y el modelo de circuitos cuánticos.

3.2 Espacio de estados: exponencial por diseño

Un registro de n qubits se describe por un vector unitario en un espacio de Hilbert de dimensión 2^n :

$$|\psi\rangle = \sum_{x \in \{0,1\}^n} \alpha_x |x\rangle, \quad \sum_x |\alpha_x|^2 = 1, \quad \alpha_x \in \mathbb{C}. \quad (2)$$

Agregar *un* qubit *duplica* la dimensión. Una sola compuerta unitaria actúa linealmente sobre las 2^n amplitudes simultáneamente. Este es el sentido preciso del “paralelismo cuántico”: crecimiento lineal en hardware produce crecimiento exponencial en el espacio de estados descriptivo. Ninguna arquitectura clásica comparte esta propiedad; una máquina clásica con P procesadores tiene una capacidad útil que crece *polinomialmente* con P .

3.3 Por qué la narrativa popular es incorrecta

Es tentador—y muy extendido—concluir que un computador cuántico “evalúa 2^n soluciones en paralelo y por lo tanto es 2^n veces más rápido”. Esto es falso, por tres razones:

1. **La medición.** Leer el registro colapsa el estado y devuelve un *único* resultado x con probabilidad $|\alpha_x|^2$. Las 2^n amplitudes no son accesibles individualmente.
2. **La cota de Holevo.** De n qubits pueden extraerse a lo sumo n bits clásicos de información.
3. **No-clonación.** La información cuántica no puede copiarse para eludir la medición.

La verdadera fuente de la ventaja cuántica es la *interferencia*: los algoritmos se coreografían para que las amplitudes de las respuestas incorrectas se cancelen destructivamente mientras las amplitudes de las respuestas correctas se refuerzan constructivamente antes de medir. Esto requiere estructura matemática explotable en el problema. Donde tal estructura existe (la búsqueda de períodos en el algoritmo de Shor mediante la transformada cuántica de Fourier), la aceleración puede ser exponencial; donde no existe (búsqueda no estructurada), la mejor aceleración posible es cuadrática (Grover), y esa cota es demostrablemente óptima.

4 Comparación formal: teoría de la complejidad

4.1 Clases y separaciones

Sean P, BPP y BQP las clases de problemas resolubles en tiempo polinomial de manera determinista, probabilística y por un computador cuántico con error acotado, respectivamente. Se sabe que $P \subseteq BPP \subseteq BQP \subseteq PSPACE$. La conjetura ampliamente aceptada—pero no demostrada—de que $BPP \subsetneq BQP$ es el enunciado formal de la ventaja cuántica. Su evidencia más fuerte es el

algoritmo de Shor: la factorización de enteros está en BQP con costo $O((\log N)^3)$, mientras que el mejor algoritmo clásico, la criba general del cuerpo de números (GNFS), es subexponencial:

$$L_N\left[\frac{1}{3}, \sqrt[3]{64/9}\right] = \exp\left(\left(\sqrt[3]{64/9} + o(1)\right)(\ln N)^{1/3}(\ln \ln N)^{2/3}\right). \quad (3)$$

Ninguna cantidad de paralelismo clásico cambia este panorama: distribuir un algoritmo subexponencial entre P procesadores divide la constante, no el exponente.

4.2 La tesis extendida de Church–Turing

La afirmación más profunda en juego es la *tesis extendida de Church–Turing*: que cualquier modelo de cómputo físicamente realizable puede simularse con una máquina de Turing probabilística con sobrecosto polinomial. La computación cuántica es el único desafío físico creíble a esta tesis. El paralelismo clásico, en cambio, está completamente contenido en ella.

4.3 Grover y los límites de la aceleración genérica

El algoritmo de Grover encuentra un elemento marcado entre N con $O(\sqrt{N})$ consultas al oráculo, frente a $\Theta(N)$ clásicamente, y la cota cuadrática es óptima (Bennett–Bernstein–Brassard–Vazirani). Este es un punto crítico de honestidad para cualquier comparación: para la búsqueda genérica y para la mayoría de las cargas de álgebra lineal densa, CFD y dinámica molecular que dominan los centros de HPC, no se conoce aceleración cuántica exponencial alguna, y los sistemas clásicos de exaescala seguirán siendo superiores en el futuro previsible.

4.4 El costo de la simulación clásica de sistemas cuánticos

La comparación inversa cuantifica la asimetría. Almacenar el vector de estado de n qubits en doble precisión requiere 2^{n+4} bytes: 45 qubits $\approx$ 0,5 PB; 50 qubits $\approx$ 16 PB; 53 qubits exceden la memoria agregada de cualquier máquina del TOP500. Los métodos de contracción de redes tensoriales han empujado repetidamente esta frontera—notablemente al re-simular los circuitos de la “supremacía cuántica” de 2019 mucho más rápido de lo afirmado originalmente—pero su costo sigue creciendo exponencialmente con el entrelazamiento del circuito. El intercambio supremacía-vs-simulación de 2019–2023 entre Google y los equipos de simulación clásica es en sí mismo un elegante caso de estudio de la tensión central de este artículo.

5 Tecnologías de implementación de qubits y perspectivas de escalado

La ventaja teórica de la Sección 4 solo es realizable si los qubits pueden fabricarse, controlarse y corregirse de errores a escala. Este capítulo examina las principales tecnologías y evalúa, con la evidencia actual, cuáles ofrecen el camino de escalado más creíble a corto plazo.

5.1 Qubits superconductores (transmones)

Circuitos de uniones Josephson operados a ~ 15 mK en refrigeradores de dilución. **Fortalezas:** compuertas rápidas (10–100 ns), fabricación litográfica que aprovecha procesos de semiconductores, el ecosistema más maduro (IBM, Google, Rigetti); la generación Heron de IBM introduce acopladores sintonizables para suprimir el crosstalk, y su hoja de ruta pública apunta a la tolerancia a fallos modular (Kookaburra 2026, Cockatoo 2027, Starling $\sim$ 2029 con $\sim$ 200 qubits lógicos y 10^8 operaciones). **Debilidades:** tiempos de coherencia cortos (decenas–cientos de μ s), fidelidades de compuerta de dos qubits en torno a 99–99,9%, conectividad solo entre vecinos próximos, y enorme sobrecarga de cableado criogénico por qubit. **Perspectiva de escalado:**

fuerte a corto plazo mediante modularidad de chips y códigos correctores qLDPC que reducen la sobrecarga de qubits físicos por lógico en aproximadamente un orden de magnitud respecto a los códigos de superficie.

5.2 Iones atrapados

Iones atómicos (Yb^+ , Ca^+) confinados en trampas electromagnéticas y manipulados con láseres (IonQ, Quantinuum). **Fortalezas:** las fidelidades de compuerta más altas demostradas ($>99,8\%$ en dos qubits), coherencia larga (segundos–minutos), conectividad todos-con-todos dentro de la trampa, qubits idénticos por naturaleza. **Debilidades:** compuertas lentas (μs – ms), y las trampas se saturan en decenas de iones; escalar requiere arquitecturas QCCD de transporte de iones o interconexiones fotónicas entre trampas, ambas intensivas en ingeniería. **Perspectiva de escalado:** calidad excelente pero crecimiento más lento en número de qubits; la plataforma líder para las primeras demostraciones de qubits lógicos, con un camino plausible a mediano plazo mediante redes fotónicas modulares.

5.3 Átomos neutros

Arreglos de átomos (Rb, Sr) sostenidos en pinzas ópticas y entrelazados mediante estados de Rydberg (Pasqal, QuEra, Atom Computing). **Fortalezas:** arreglos demostrados de más de 1.000 átomos físicos, geometría reconfigurable (2D/3D), aparato de vacío a temperatura ambiente en lugar de refrigeración por dilución, ajuste natural para simulación cuántica analógica. **Debilidades:** fidelidades históricamente inferiores a iones y transmones (mejorando rápidamente), pérdida de átomos, tasas de ciclo lentas. **Perspectiva de escalado:** posiblemente el escalado más rápido en número bruto de qubits demostrado hasta la fecha; experimentos recientes con qubits lógicos (compuertas transversales sobre decenas de qubits lógicos) han colocado a esta plataforma, inesperadamente, al frente de la carrera de la corrección de errores. Candidata líder si las fidelidades siguen mejorando.

5.4 Qubits fotónicos

Información codificada en fotones procesados mediante óptica lineal y computación basada en mediciones (PsiQuantum, Xanadu). **Fortalezas:** operación a temperatura ambiente (excepto los detectores), interconexión natural por fibra óptica, aprovechamiento de las fábricas de fotónica de silicio. **Debilidades:** los fotones no interactúan directamente—las compuertas de dos qubits son probabilísticas y exigen una enorme sobrecarga de multiplexación; la pérdida de fotones es el error dominante. **Perspectiva de escalado:** una apuesta de alto riesgo y alta recompensa, de “todo o nada”, sobre la escala de manufactura; si las redes de fusión basadas en foundries tienen éxito, son concebibles sistemas de millones de qubits, pero los hitos intermedios son escasos.

5.5 Qubits de espín en silicio

Espines de electrones o núcleos en puntos cuánticos de silicio o átomos donantes (Intel, Diraq, UNSW). **Fortalezas:** huella del qubit de nanómetros, compatibilidad directa con la manufactura CMOS—la única tecnología que podría montarse sobre la industria de semiconductores existente; resultados recientes muestran coherencia de espín nuclear superior a 30 s y tasas de error inferiores al 1%, con entrelazamiento demostrado entre núcleos donantes separados 20 nm. **Debilidades:** recuentos de dispositivos actualmente pequeños (decenas de qubits), variabilidad entre puntos cuánticos, integración de la electrónica de control a milikelvin. **Perspectiva de escalado:** potencialmente la mejor historia de escalado a largo plazo (miles de millones de transistores ya caben en un die), pero la más lejana de demostrar sistemas de escala intermedia.

5.6 Qubits topológicos

Qubits codificados en aniones no abelianos (modos cero de Majorana), perseguidos por Microsoft. **Fortalezas:** protección contra errores incorporada en la física—la codificación topológica suprimiría intrínsecamente el ruido local, recortando drásticamente la sobrecarga de corrección de errores. **Debilidades:** la existencia y el control de las cuasipartículas subyacentes fueron disputados durante años; los dispositivos están en etapa de validación de pocos qubits. **Perspectiva de escalado:** transformadora si funciona; el mayor riesgo científico de todas las plataformas.

5.7 Evaluación comparativa

Tecnología	Fidelidad 2Q	Vel. compuerta	Escala demostrada	Conectividad	Escalado corto p
Superconductores	99–99,9%	10–100 ns	~100–1.000+ fís.	vecinos próximos	Alto
Iones atrapados	>99,8%	μ s–ms	decenas por trampa	todos-con-todos	Medio
Átomos neutros	99–99,5%	μ s	>1.000 átomos	reconfigurable	Alto
Fotónicos	n/a (fusión)	ns	componentes	nativa de red	Incierto
Espín en silicio	~99%	ns– μ s	decenas	vecinos próximos	Alto a largo pla
Topológicos	—	—	validación	—	Especulativo

Cuadro 1: Comparación cualitativa de plataformas de qubits (valores representativos de 2026).

Con la evidencia actual, **los circuitos superconductores y los átomos neutros ofrecen los caminos de escalado más creíbles a corto plazo**—los primeros mediante hojas de ruta industriales, acoplamiento modular de chips y códigos qLDPC eficientes; los segundos mediante arreglos masivos y reconfigurables de átomos y un progreso rápido en operaciones con qubits lógicos. Los iones atrapados lideran en fidelidad y probablemente albergarán los primeros qubits lógicos de mayor calidad. Los espines en silicio son la apuesta más fuerte a *largo plazo* porque heredan toda la base de manufactura CMOS. La métrica decisiva en todos los casos no es el número de qubits físicos, sino la razón de qubits físicos a lógicos y la tasa de error lógico por operación.

6 La realidad de 2026: exaescala vs. NISQ

6.1 Clásico: exaescala verificada

La lista TOP500 de junio de 2026 está encabezada por LineShine (Centro Nacional de Supercomputación, Shenzhen) con 2,198 exaflops en HPL—notablemente una arquitectura de solo CPU—seguida por El Capitan (LLNL) con 1,809 exaflops, con Frontier y Aurora también por encima del exaflop. Estos sistemas agregan del orden de 10^7 núcleos, consumen 30–42 MW y descansan sobre cincuenta años de software maduro: MPI, OpenMP, CUDA/HIP, sistemas de archivos paralelos resilientes y tolerancia a fallos por checkpoint-restart.

6.2 Cuántico: la era NISQ

El hardware cuántico en 2026 permanece en el régimen que Preskill llamó NISQ: dispositivos ruidosos de aproximadamente 50 a ~1.000 qubits físicos, sin corrección de errores completa, donde la decoherencia limita la profundidad de circuito ejecutable a miles de compuertas. Los qubits físicos no son qubits lógicos: la corrección de errores con códigos de superficie exige del orden de 10^2 – 10^3 qubits físicos por qubit lógico a las tasas de error actuales, razón por la cual las hojas de ruta de los fabricantes (p. ej., IBM Starling, ~2029, ~200 qubits lógicos y 10^8 operaciones cuánticas) tratan la máquina tolerante a fallos como una meta de fin de década y no como una realidad presente.

6.3 La asimetría de las dificultades de escalado

La comparación expone una asimetría notable. El HPC clásico escala fácilmente en hardware pero está acotado asintóticamente: su aceleración es lineal en los recursos y no puede salir de su clase de complejidad. La computación cuántica es asintóticamente ilimitada en problemas estructurados, pero escala con enorme dificultad en hardware: agregar qubits agrega ruido, crosstalk, cableado y carga criogénica, y el impuesto de la corrección de errores debe pagarse antes de que se materialice cualquier ventaja asintótica. Millones de núcleos robustos frente a cientos de qubits frágiles; la carrera es entre la madurez de la ingeniería y el destino matemático.

7 Convergencia: el modelo híbrido HPC+QC

El futuro realista no es el reemplazo sino la integración, reflejando cómo las GPU entraron al nodo hace dos décadas. Las unidades de procesamiento cuántico (QPU) ya se están co-ubicando con supercomputadores (p. ej., sistemas cuánticos instalados en Jülich y en laboratorios nacionales) y se exponen mediante runtimes híbridos en los que la máquina clásica realiza el preprocesamiento, la optimización de parámetros variacionales, la mitigación de errores y el posprocesamiento, mientras la QPU ejecuta el kernel clásicamente intratable: simulación cuántica de moléculas y materiales, búsqueda de períodos y, prospectivamente, subrutinas cuánticas de álgebra lineal. El estado final de la confrontación que da título a este artículo es, entonces, un diagrama de arquitectura y no una victoria: el clúster de exaescala con un criostato en la sala de máquinas.

8 Conclusiones

(1) El paralelismo clásico, desde el ILP hasta la exaescala, entrega a lo sumo una aceleración lineal en recursos físicos y no puede alterar la clase de complejidad de un problema. (2) El paralelismo cuántico no es evaluación paralela sino espacio de estados exponencial más interferencia; produce ventaja superpolinomial solo para problemas estructurados, exponencial en los mejores casos (factorización, simulación cuántica) y apenas cuadrática para la búsqueda no estructurada. (3) La premisa de que la computación cuántica es potencialmente más poderosa sobrevive, por tanto, intacta a la exaescala—de hecho, la exaescala misma, incapaz de simular exactamente más de ~ 50 qubits, es el testigo empírico más limpio de la brecha. (4) Entre las tecnologías de implementación, los circuitos superconductores y los átomos neutros presentan actualmente los caminos de escalado más creíbles a corto plazo, los iones atrapados la mayor fidelidad, y los espines en silicio la historia de manufactura más sólida a largo plazo; la métrica que gobierna son los qubits lógicos, no los físicos. (5) La trayectoria práctica es híbrida: QPU como aceleradores dentro del HPC clásico, cada paradigma haciendo lo que el otro demostrablemente no puede.

Referencias

- [1] R. P. Feynman, “Simulating physics with computers,” *Int. J. Theor. Phys.*, 21(6/7):467–488, 1982.
- [2] D. Deutsch, “Quantum theory, the Church–Turing principle and the universal quantum computer,” *Proc. R. Soc. Lond. A*, 400:97–117, 1985.
- [3] P. W. Shor, “Algorithms for quantum computation: discrete logarithms and factoring,” *Proc. 35th FOCS*, 124–134, 1994.
- [4] L. K. Grover, “A fast quantum mechanical algorithm for database search,” *Proc. 28th STOC*, 212–219, 1996.

- [5] C. H. Bennett, E. Bernstein, G. Brassard, U. Vazirani, “Strengths and weaknesses of quantum computing,” *SIAM J. Comput.*, 26(5):1510–1523, 1997.
- [6] J. Preskill, “Quantum computing in the NISQ era and beyond,” *Quantum*, 2:79, 2018.
- [7] M. A. Nielsen e I. L. Chuang, *Quantum Computation and Quantum Information*, Cambridge Univ. Press, 2010.
- [8] G. M. Amdahl, “Validity of the single processor approach to achieving large scale computing capabilities,” *AFIPS Conf. Proc.*, 30:483–485, 1967.
- [9] J. L. Gustafson, “Reevaluating Amdahl’s law,” *Commun. ACM*, 31(5):532–533, 1988.
- [10] J. L. Hennessy y D. A. Patterson, *Computer Architecture: A Quantitative Approach*, 6.^a ed., Morgan Kaufmann, 2019.
- [11] F. Arute *et al.*, “Quantum supremacy using a programmable superconducting processor,” *Nature*, 574:505–510, 2019.
- [12] Proyecto TOP500, “Lista de junio de 2026,” <https://www.top500.org>, consultado en julio de 2026.
- [13] IBM, “IBM Quantum Development Roadmap: computación cuántica tolerante a fallos para 2029 (Starling),” 2025.
- [14] A. S. Holevo, “Bounds for the quantity of information transmitted by a quantum communication channel,” *Probl. Inf. Transm.*, 9:177–183, 1973.